

Fama–French (1993) 三因子构造的复现与扩展

实证报告 · ECON6067 独立项目 复现对象：Fama, E. F. & French, K. R. (1993), "Common Risk Factors in the Returns on Stocks and Bonds," *Journal of Financial Economics*, 33(1), 3–56.

1. 研究问题与动机

Fama 和 French (1993) 提出的核心问题是：**股票收益的横截面差异能否被少数几个共同因子概括？** 他们识别出三个股票市场因子——市场超额收益 (MKT-RF)、规模因子 (SMB) 和账面市值比因子 (HML)，并证明这些因子能解释大部分按规模与账面市值比排序组合的收益差异。

本项目的目标不是复现论文中的每一个检验，而是**聚焦于因子构造本身**：从原始 CRSP / Compustat 数据出发，重建 2000–2025 年的月度 MKT-RF、SMB 和 HML 序列，与 Kenneth French 数据库的官方序列对比，并在其基础上完成一项独立扩展。这一过程的可迁移价值在于：它覆盖了"原始数据 → 样本清洗 → 变量定义 → 组合排序 → 因子构造 → 验证"的完整实证工作流，适用于任何需要从微观数据构造宏观序列或指数的工作。

2. 数据来源、样本构建与变量定义

2.1 数据来源

数据	来源	用途
CRSP Monthly Stock	课程包 02 (<code>monthly_stock.csv</code> , 2000–2025, 242 万行)	月度收益、价格、流通股数、市值、市场收益
F-F 因子与无风险利率	课程包 02 (<code>F-F factors and RF.csv</code>)	官方基准因子 + RF
Compustat Annual	课程包 04 (<code>Compustat.csv</code>)	账面权益的会计科目
CRSP-Compustat 链接表	课程包 04 (<code>CCM.csv</code>)	将 Compustat 公司 (gvkey) 链接到 CRSP 证券 (permno)

原始数据为受限数据，不进入 GitHub 仓库；获取方式见 `README.md`。

2.2 样本筛选 (universe)

因子构造遵循 Fama–French 的"美国普通股"口径，保留同时满足以下条件的证券-月份观测：

字段	条件	含义
SecurityType	EQTY	普通股权（剔除约 64 万基金观测）
ShareType	NS	普通普通股（剔除 ADR、单位等）
USIncFlg	Y	美国注册公司
IssuerType	CORP	经营公司（剔除 REIT 与非经营主体）
PrimaryExch	N / A / Q	NYSE / NYSE American / NASDAQ

筛选后为 1,339,565 个证券-月份、12,949 只证券。NYSE 断点只使用 PrimaryExch = "N" 的股票计算（FF 惯例）。

数据质量处理：原始 monthly_stock.csv 中存在完全重复的（PERMNO, 月份）行（共 2,755 行，源于数据源多表 join 的产物）。这些重复行会使价值加权重重复计数、严重扭曲组合收益（例如 2001 年 7 月的 S/L 组合被错误算成 +19.79%，实际约 -4.5%）。因此按（PERMNO, YYYYMM）去重，每个证券-月份只保留一条。

2.3 变量定义

市场权益 (ME)： $ME = MthCap / 1000$ （单位：百万美元）。MthCap 已等于价格 × 流通股数（千美元），负价格取绝对值由数据源处理。

账面权益 (BE)： 按 Fama–French 定义构建：

BE = SEQ + TXDITC - 优先股

优先股 = PSTKRV（赎回价值），缺失则 PSTKL（清算价值），再缺失则 PSTK（账面价值），再缺失为 0

若 SEQ 缺失：BE = CEQ + PSTK

若 SEQ、CEQ 均缺失：BE = AT - LT

其中 TXDITC（递延税 + 投资税收抵免）缺失按 0 处理。仅保留 BE > 0 的观测（94,523 个公司-年度）。
注：describe.md 中提到的 TXDB 字段在实际数据中为 txditc，二者含义一致（递延税与投资税收抵免）。

账面市值比 (BM)： 对第 t 年 6 月的排序， $BM = BE(\text{财年结束于 } t-1 \text{ 年}) / ME(\text{第 } t-1 \text{ 年 } 12 \text{ 月})$ 。会计年度以 datadate 的日历年标识（即"财年结束于日历年 t-1"），保证会计数据在 6 月排序时已可用（至少 6 个月滞后）。

CRSP-Compustat 链接： 保留主链接或条件主链接（LINKPRIM ∈ {P, C}）且类型为当前/未研究（LINKTYPE ∈ {LC, LU}）的链接；并施加链接有效期（LINKDT ≤ datadate ≤ LINKENDDT，E 表示仍有效）。同一（permno,

财年) 若有多条 BE, 取 `datadate` 最新者。

退市处理: 数据无独立退市收益字段 (仅有退市标志 `MthDelFlg`, 全样本退市事件约 1,177 起), `MthRet` 已包含可获得的总收益。此点与官方基准存在轻微差异, 但对价值加权组合影响极小, 作为已记录的局限。

3. 实证设计

每年 6 月底, 用 NYSE 股票确定断点, 将全样本股票分为 2 个规模组 $\times$ 3 个账面市值比组:

- 规模:** `Small` = ME(6月) < NYSE 中位数; `Big` = 其余
- 账面市值比:** `Low` < 30% 分位; `Medium` $\in$ [30%, 70%]; `High` > 70% 分位 (均为 NYSE 分位)

形成 6 个组合 S/L、S/M、S/H、B/L、B/M、B/H, 从当年 7 月持有到次年 6 月。组合月收益为**价值加权** (权重 = 月初市值 = 上月末 ME) 。

三因子构造:

$$\begin{aligned} \text{MKT-RF} &= \text{vwretd} - \text{RF} \\ \text{SMB} &= (\text{S/L} + \text{S/M} + \text{S/H})/3 - (\text{B/L} + \text{B/M} + \text{B/H})/3 \\ \text{HML} &= (\text{S/H} + \text{B/H})/2 - (\text{S/L} + \text{B/L})/2 \end{aligned}$$

其中 `vwretd` 为 CRSP 全市场价值加权收益, RF 取自官方基准数据。样本 2000–2025 年, 因子序列从 2001 年 7 月 (首次 6 月排序之后) 至 2025 年 12 月, 共 294 个月。

4. 核心复现结果与原文比较

4.1 描述统计 (月度, 2001-07 至 2025-12)

因子	均值(%)	标准差(%)	t 值	年化均值(%)	年化 Sharpe
MKT-RF (构造)	0.68	4.43	2.64	8.50	0.55
MKT-RF (官方)	0.73	4.44	2.82	9.13	0.59
SMB (构造)	0.18	2.62	1.19	2.20	0.24
SMB (官方)	0.06	2.60	0.42	0.77	0.09
HML (构造)	-0.00	3.13	-0.00	-0.00	-0.00
HML (官方)	0.04	3.09	0.19	0.42	0.04

4.2 相关性

因子	月度相关性	R ²
MKT-RF	0.9973	0.994
SMB	0.9616	0.925
HML	0.9539	0.910

4.3 跟踪回归（构造值 = $\alpha + \beta \times$ 官方值）

因子	α (%/月)	β	R ²
MKT-RF	-0.05	0.995	0.994
SMB	+0.12	0.967	0.925
HML	-0.03	0.967	0.910

跟踪回归显示 α 均接近 0（3–12 bp/月）， β 接近 1，说明构造因子与官方序列在水平和波动上高度一致。累计收益曲线（`output/figures/cumulative_*.png`）中，构造序列与官方序列几乎重合。

4.4 差异来源

HML 的相关性随时期变化明显（`correlation_by_subperiod.csv`）：

时期	HML 相关性
2001–2005	0.782
2006–2010	0.958
2011–2015	0.952
2016–2020	0.973
2021–2025	0.985

早期（2001–2005）HML 差异最大，之后逐步收敛。主要差异来源（均为可解释的正常偏差）：

- 1. **数据版本**：官方因子基于 Kenneth French 当年计算时的 Compustat 数据 vintage，而本项目使用当前 (restated) Compustat。早期样本（互联网泡沫时期）的会计数据 restatement 影响相对更大。
- 2. **样本覆盖**：早期 Compustat 对小市值/新兴公司的覆盖较低，影响 High-BM 组的构成。
- 3. **账面权益的精确定义**：优先股科目（`pstkrv / pstkl / pstk`）在早期报告口径不同，导致 BE 略有差异。

4. **规模分位**：本项目 SMB 的 $\beta = 0.967$ 、均值略高 (0.18% vs 0.06%)，反映样本规模分布与官方略有不同。

这些差异的方向与文献中"复现官方因子通常存在 3–8% 的月度相关性缺口"的经验一致；本项目 HML 相关性 0.95 已属高质量复现。

5. 独立扩展：动量因子与三/四因子模型比较

5.1 动机与经济问题

三因子模型的一个著名遗漏是**动量**：Carhart (1997) 发现，加入"赢家减输家" (WML) 动量因子能显著改善模型对收益的解释力。本扩展提出一个明确问题：**在 2000–2025 年样本中，动量因子是否仍在三因子之外提供增量解释力？** 这一问题既有文献基础，又因动量溢价在 2000 年后的明显减弱而具有现实张力。

5.2 构造与检验设计

- 动量因子**：每月用"过去 2–12 月累计收益 (跳过最近一月)"作为信号，按 NYSE 断点做 2 (规模) × 3 (动量) 排序， $WML = (S/W + B/W)/2 - (S/L + B/L)/2$ ，每月再平衡。WML 序列 300 个月 (2001-01 至 2025-12)，均值 +0.12%/月、标准差 4.87%、 $t = 0.43$ 。
- 检验资产**：25 个 size-B/M 组合 (5×5 NYSE 五分位排序，每年 6 月再平衡，价值加权)。
- 检验方法**：对每个组合做时间序列回归，比较三因子与四因子模型的 **GRS 检验**、平均绝对 α 、平均 R^2 。

5.3 结果

模型	GRS	p 值	平均 $ \alpha $ (%/月)	平均 R^2	显著 α 占比
FF3	5.33	< 0.001	0.230	0.901	64%
FF4	5.10	< 0.001	0.223	0.902	64%

子样本 (ff4_model_comparison_subperiod.csv)：

时期	模型	GRS	平均 $ \alpha $ (%/月)	平均 R^2
2001–2012	FF3 → FF4	2.68 → 2.81	0.244 → 0.237	0.900 → 0.903
2013–2025	FF3 → FF4	4.24 → 4.05	0.220 → 0.220	0.912 → 0.913

5.4 解释

结果支持一个**谨慎而诚实**的结论：在 2000–2025 年样本中，动量因子对三因子的增量解释力**有限**——全样本 GRS 仅从 5.33 降至 5.10，平均绝对 α 仅下降 0.007%/月，且两个模型均被 GRS 检验强烈拒绝（25 个 size-B/M 组合的定价误差仍然显著）。子样本进一步揭示**时期依赖**：2001–2012 年加入动量反而略微恶化 GRS（对应 2009 年著名的动量崩盘），而 2013–2025 年略有改善。

这与文献共识一致：美国动量溢价在 2000 年后大幅减弱，Carhart 四因子相对三因子的边际价值随样本期与检验资产的不同而波动。本扩展的价值在于：通过标准化的 GRS 框架量化了这一边际价值，并揭示了其时期异质性——这是一个比“加入动量必然改善模型”更有信息量的发现。

6. 验证、局限性与结论

6.1 验证

- 市场因子一致性**：CRSP `vwretd` 与官方 `Mkt-RF + RF` 的相关性达 0.999，验证了 RF 与市场收益的对应关系，MKT-RF 的复现基本精确。
- 数值与单位核对**：官方因子为百分数、CRSP 收益为小数，全部统一为小数后比较；基准文件解析时跳过说明头与年度行，仅取 6 位 `YYYYMM` 月度行。
- 数据质量检查**：识别并去除完全重复的证券-月份行，避免价值加权重复计数。

6.2 局限性

- 无独立退市收益字段，退市处理仅做最小化处理。
- Compustat 数据为当前 vintage，与官方因子的历史 vintage 存在固有差异。
- 因子序列从 2001 年 7 月起（需首次 6 月排序），比官方序列少 6 个月。
- 动量因子的 12–1 窗口、30/70 断点为标准设定，未做窗口稳健性检验。

6.3 结论

本项目从原始 CRSP/Compustat 数据出发，成功重建了 2000–2025 年月度 MKT-RF、SMB、HML 三因子：市场因子与官方序列几乎重合 ($\rho = 0.997$)，SMB ($\rho = 0.962$) 与 HML ($\rho = 0.954$) 也达到高质量复现，跟踪回归 α 接近 0、 β 接近 1。差异主要来自数据版本与样本覆盖，且集中在早期样本。独立扩展部分构造了动量因子并完成三/四因子比较，发现动量在 2000–2025 年对三因子仅有边际增量解释力且呈时期依赖，与文献中动量溢价减弱的证据一致。全部结果可由 `code/` 下按序执行的脚本从原始数据一键复现。